## Непараметрическая регрессия

#### Цели работы:

- 1) практика первичных навыков обработки данных: нормализация, One-Hot преобразование;
- 2) сведение задачи классификации к задаче непараметрической регрессии;
- 3) реализация решения задачи непараметрической регрессии ядерным сглаживанием Надарая Ватсона;
- 4) практика наивного способа настройки и анализа гиперпараметров модели, решающей задачу непараметрической регрессии.

#### Набор данных

Выберите любой понравившийся набор данных для задачи классификации из следующего списка:

- 1. car <a href="https://www.openml.org/d/40975">https://www.openml.org/d/40975</a>
- 2. vehicle <a href="https://www.openml.org/d/54">https://www.openml.org/d/54</a>
- 3. wine <a href="https://www.openml.org/d/187">https://www.openml.org/d/187</a>
- 4. bridges <a href="https://www.openml.org/d/327">https://www.openml.org/d/327</a>

#### Сведение к задаче регрессии и обработка данных

Перейдите от задачи классификации к задаче регрессии, используя <u>OneHot</u> преобразование. Вместо одного целевого признака в выбранный набор данных добавляется столько новых числовых переменных, сколько в нём содержится классов. Помимо этого, если выбранный Вами набор данных содержит нечисловые признаки, эти признаки необходимо векторизовать (перейти от категорий к числам), заполнить пропуски (если есть) и нормализовать. В наборе данных bridges также необходимо избавиться от столбца IDENTIF, поскольку он является идентификатором записи.

# Реализация алгоритма и настройка гиперпараметров, анализ результатов

Реализуйте алгоритм решения задачи непареметрической регрессии при помощи ядерного сглаживания Надарая-Ватсона.

Найдите лучшую комбинацию гиперпараметров алгоритма непараметрической регрессии:

- функция расстояния:
  - расстояние Евклида,
  - расстояние Манхэттена,
  - о расстояние Чебышева;
- функция ядра

$$\circ$$
 uniform:  $K(u)=rac{1}{2}$ 

$$\circ$$
 triangular:  $K(u)=(1-|u|)$ 

$$\circ$$
 epanechnikov:  $K(u)=rac{3}{4}(1-u^2)$ 

$$\circ$$
 quartic:  $K(u)=rac{15}{16}(1-u^2)^2$ 

- тип окна (окно, зависящее от количества соседей и фиксированное)
- параметр окна:
  - $\circ$  количество ближайших соседей от 1 до  $\sqrt{|D|},\ |D|$  размер набора данных,  $\sqrt{|D|}$  является эвристикой на число ближайших соседей для метрических алгоритмов **ИЛИ**
  - $\circ$  размер окна, его необходимо выбирать исходя из "размеров" набора данных; хорошей практикой является настройка ширины окна на отрезке  $\left[\frac{R(D)}{\sqrt{|D|}};R(D)\right]$  с шагом R(D) /  $\sqrt{|D|}$ , где R(D) самое большое расстояния между элементами в наборе данных.

Таким образом требуется перебрать  $24\sqrt{|D|}$  комбинаций гиперпараметров и <u>найти лучшую</u>.

Используйте Leave-One-Out перекрёстную проверку для настройки алгоритма.

Критерием качества является F-мера. Для её подсчёта потребуется определить максимальную компоненту результирующего вектора целевых признаков, полученных из One-Hot преобразования, после применения очередной конфигурации алгоритма непараметрической регрессии (алгоритм с одной из комбинаций гиперпараметров).

Для лучшей найденной комбинации гиперпараметров постройте графики зависимости F-меры от числа <u>ближайших соседей</u> **или** <u>ширины окна</u> (при фиксированных лучших значениях прочих гиперпараметров).

### Схема работы

